

Exemplu complet de funcționare a unui MLP

Clasificare binară: predicția cumpărării unui produs

Scop: să urmărim numeric, pas cu pas, cum un MLP transformă datele de intrare într-o probabilitate, apoi calculează eroarea și actualizează ponderile.

1. Setul de date didactic

Folosim un set mic de date pentru 5 clienți. Valorile nu provin dintr-o companie reală, dar toate calculele de mai jos sunt exacte și complet determinate.

Client	Vârsta	Venit lunar, MDL	Vizite pe site	A cumpărat
A	20	3000	0	0
B	30	8000	3	0
C	36	15000	8	1
D	50	18000	7	1
E	60	23000	10	1

Vom urmări clientul C:

Age = 36, Income = 15000, Visits = 8

Arhitectură: 3 intrări -> 4 neuroni ascunși -> 1 neuron de ieșire

2. Scalarea datelor

Aplicăm Min-Max Scaling pentru fiecare variabilă:

$$x' = (x - x_{\min}) / (x_{\max} - x_{\min})$$

$$\text{Vârsta: } (36 - 20) / (60 - 20) = 16 / 40 = 0.4$$

$$\text{Venit: } (15000 - 3000) / (23000 - 3000) = 12000 / 20000 = 0.6$$

$$\text{Vizite: } (8 - 0) / (10 - 0) = 0.8$$

$$X = [0.4, 0.6, 0.8]$$

3. Calculul neuronilor din stratul ascuns

Pentru fiecare neuron calculăm mai întâi suma ponderată z , apoi aplicăm funcția ReLU:

$$z = x_1 * w_1 + x_2 * w_2 + x_3 * w_3 + b$$

$$\text{ReLU}(z) = \max(0, z)$$

Neuronul 1

$$w = [0.5, -0.2, 0.8], \quad b = 0.1$$

$$z_1 = 0.4 * 0.5 + 0.6 * (-0.2) + 0.8 * 0.8 + 0.1$$

$$z_1 = 0.20 - 0.12 + 0.64 + 0.10 = 0.82$$

$$h_1 = \text{ReLU}(0.82) = 0.82$$

Neuronul 2

$$w = [-0.4, 0.9, 0.1], \quad b = -0.2$$

$$z_2 = 0.4 * (-0.4) + 0.6 * 0.9 + 0.8 * 0.1 - 0.2$$

$$z2 = -0.16 + 0.54 + 0.08 - 0.20 = 0.26$$

$$h2 = \text{ReLU}(0.26) = 0.26$$

Neuronul 3

$$w = [0.3, 0.2, -0.7], \quad b = 0.05$$

$$z3 = 0.4*0.3 + 0.6*0.2 + 0.8*(-0.7) + 0.05$$

$$z3 = 0.12 + 0.12 - 0.56 + 0.05 = -0.27$$

$$h3 = \text{ReLU}(-0.27) = 0$$

Neuronul 4

$$w = [0.6, 0.4, 0.2], \quad b = -0.1$$

$$z4 = 0.4*0.6 + 0.6*0.4 + 0.8*0.2 - 0.1$$

$$z4 = 0.24 + 0.24 + 0.16 - 0.10 = 0.54$$

$$h4 = \text{ReLU}(0.54) = 0.54$$

Rezultatul stratului ascuns: $h = [0.82, 0.26, 0, 0.54]$

Interpretare: h este vectorul ieșirilor celor 4 neuroni din stratul ascuns, după aplicarea funcției de activare ReLU.

4. Neuronul de ieșire

Neuronul final primește valorile din h . Ponderile sale sunt:

$$w = [1.2, -0.7, 0.5, 0.8], \quad b = -0.3$$

$$z = 0.82*1.2 + 0.26*(-0.7) + 0*0.5 + 0.54*0.8 - 0.3$$

$$z = 0.984 - 0.182 + 0 + 0.432 - 0.3 = 0.934$$

5. Transformarea în probabilitate - Sigmoid

$$\text{Sigmoid}(z) = 1 / (1 + \exp(-z))$$

$$P = 1 / (1 + \exp(-0.934)) = 0.7179$$

Probabilitatea estimată de cumpărare = 71.8%

Dacă pragul de clasificare este 0.5, atunci $0.7179 > 0.5$, deci predicția este $y_{\text{hat}} = 1$ (clientul va cumpăra). În setul de date, pentru clientul C valoarea reală este $y = 1$, deci clasificarea este corectă.

6. Calcularea erorii

Pentru clasificare binară folosim Binary Cross-Entropy. Deoarece $y = 1$:

$$\text{Loss} = -\ln(P)$$

$$\text{Loss} = -\ln(0.717886) = 0.3314$$

Modelul poate clasifica corect și totuși să aibă o pierdere nenulă, deoarece probabilitatea estimată nu este 100%.

7. Backpropagation și actualizarea unei ponderi

Pentru combinația Sigmoid + Binary Cross-Entropy, gradientul la ieșire este:

$$\text{delta} = P - y = 0.717886 - 1 = -0.282114$$

Luăm prima pondere de ieșire $w1 = 1.2$ și un learning rate $\eta = 0.1$:

$$\begin{aligned}w1_{\text{new}} &= w1 - \eta * \text{delta} * h1 \\w1_{\text{new}} &= 1.2 - 0.1 * (-0.282114) * 0.82 \\w1_{\text{new}} &= 1.2231\end{aligned}$$

Ponderea se modifică: 1.2000 -> 1.2231. Acesta este efectiv un pas de învățare.

8. Fluxul complet

1. Date client: [36, 15000, 8]
2. Scalare: [0.4, 0.6, 0.8]
3. Strat ascuns + ReLU: $h = [0.82, 0.26, 0, 0.54]$
4. Neuron ieșire: $z = 0.934$
5. Sigmoid: $P = 0.7179$
6. Prag 0.5: $y_{\text{hat}} = 1$
7. Valoare reală: $y = 1$
8. Loss = 0.3314
9. Backpropagation -> actualizarea ponderilor

9. Ideea-cheie

MLP: Date -> combinații ponderate -> activări -> predicție -> Loss -> Backpropagation -> actualizarea ponderilor.

Diferența dintre z și h : z este suma ponderată înainte de funcția de activare, iar h este ieșirea neuronului după activare. Un MLP nu are memorie temporală: fiecare observație este procesată independent.