

Exemplu simplu de funcționare a unui LSTM

Scop: să vedem cum un LSTM decide ce uită, ce păstrează în memorie și ce transmite mai departe.

Notă didactică: ponderile folosite mai jos sunt alese manual pentru a putea urmări calculele. Într-un LSTM real, ele sunt inițializate automat și apoi învățate prin Backpropagation Through Time (BPTT).

Datele exemplului

Moment	Activitate client (scalată)
Luna 1	$x_1 = 0.2$
Luna 2	$x_2 = 0.6$

Stările inițiale sunt: $h_0 = 0$ și $C_0 = 0$. Aici h reprezintă hidden state, iar C reprezintă cell state - memoria principală a LSTM.

LSTM folosește trei porți principale: Forget Gate -> Input Gate -> Output Gate, plus o memorie candidat.

1. Forget Gate - ce informație păstrăm din trecut?

Formula:

$$f_t = \text{sigmoid}(W_f x_t + U_f h_{(t-1)} + b_f)$$

Folosim $W_f = 0.5$, $U_f = 0.1$, $b_f = 0$. Pentru luna 1: $x_1 = 0.2$ și $h_0 = 0$.

$$f_1 = \text{sigmoid}(0.5 \cdot 0.2 + 0.1 \cdot 0) = \text{sigmoid}(0.1) = 0.5250$$

Interpretare: poarta uitării lasă să treacă aproximativ 52.5% din memoria precedentă. Cum $C_0 = 0$, nu există încă informație veche de păstrat.

2. Input Gate - câtă informație nouă introducem?

$$i_t = \text{sigmoid}(W_i x_t + U_i h_{(t-1)} + b_i)$$

Cu $W_i = 0.4$, $U_i = 0.2$ și $b_i = 0$:

$$i_1 = \text{sigmoid}(0.4 \cdot 0.2 + 0.2 \cdot 0) = \text{sigmoid}(0.08) = 0.5200$$

Interpretare: aproximativ 52.0% din informația nouă candidat va fi introdusă în memorie.

3. Candidate Memory - ce informație nouă ar putea fi memorată?

$$\tilde{C}_t = \tanh(W_C x_t + U_C h_{(t-1)} + b_C)$$

Cu $W_C = 0.6$, $U_C = 0.1$ și $b_C = 0$:

$$\tilde{C}_1 = \tanh(0.6 \cdot 0.2 + 0.1 \cdot 0) = \tanh(0.12) = 0.1194$$

4. Actualizarea memoriei principale

Formula centrală a LSTM este:

$$C_t = f_t * C_{(t-1)} + i_t * \tilde{C}_t$$

Pentru luna 1:

$$C_1 = 0.5250 * 0 + 0.5200 * 0.1194 = 0.0621$$

Memoria nouă este formată din două componente: ceea ce păstrăm din trecut + ceea ce adăugăm din prezent.

5. Output Gate - ce informație transmitem mai departe?

$$o_t = \text{sigmoid}(W_o x_t + U_o h_{(t-1)} + b_o)$$

Cu $W_o = 0.3$, $U_o = 0.2$ și $b_o = 0$:

$$o_1 = \text{sigmoid}(0.3 * 0.2 + 0.2 * 0) = \text{sigmoid}(0.06) = 0.5150$$

Hidden state-ul se calculează:

$$h_1 = o_1 * \tanh(C_1) = 0.5150 * \tanh(0.0621) = 0.0319$$

După prima lună: $C_1 = 0.0621$ și $h_1 = 0.0319$.

6. A doua lună

Acum $x_2 = 0.6$. LSTM primește și informația transmisă din luna 1: $h_1 = 0.0319$ și $C_1 = 0.0621$.

Componentă	Calcul	Rezultat
Forget Gate	$\text{sigmoid}(0.5 * 0.6 + 0.1 * 0.0319)$	$f_2 = 0.5752$
Input Gate	$\text{sigmoid}(0.4 * 0.6 + 0.2 * 0.0319)$	$i_2 = 0.5613$
Candidate Memory	$\tanh(0.6 * 0.6 + 0.1 * 0.0319)$	$\tilde{C}_2 = 0.3480$

7. Noua memorie după luna 2

$$C_2 = f_2 * C_1 + i_2 * \tilde{C}_2$$

$$C_2 = 0.5752 * 0.0621 + 0.5613 * 0.3480 = 0.0357 + 0.1953 = 0.2311$$

Memoria principală a crescut de la $C_1 = 0.0621$ la $C_2 = 0.2311$.

8. Hidden state pentru luna 2

$$o_2 = \text{sigmoid}(0.3 * 0.6 + 0.2 * 0.0319) = \text{sigmoid}(0.1864) = 0.5465$$

$$h_2 = o_2 * \tanh(C_2) = 0.5465 * \tanh(0.2311) = 0.1241$$

Ce trebuie să reținem?

Element	Rol
Forget Gate	Decide cât din memoria veche se păstrează.
Input Gate	Decide câtă informație nouă intră în memorie.
Candidate Memory	Propune informația nouă ce poate fi memorată.
Cell State (C)	Memoria principală transportată prin secvență.
Output Gate	Decide ce parte din memorie devine ieșire.
Hidden State (h)	Informația transmisă către pasul următor și/sau către stratul de ieșire.

Schema intuitivă

Memorie veche $C_{(t-1)}$ -> Forget Gate -> ce păstrăm
Informație nouă x_t -> Input Gate + Candidate Memory -> ce adăugăm
Cele două componente se combină -> C_t -> Output Gate -> h_t

Diferența față de RNN

RNN: folosește în principal hidden state-ul h_t ca memorie recurentă.

LSTM: folosește atât hidden state-ul h_t , cât și cell state-ul C_t , iar porțile învață ce informație trebuie uitată, păstrată sau transmisă.

Fraza-cheie: RNN memorează prin hidden state; LSTM introduce suplimentar cell state și porți care controlează memoria.